基于CNN的图像二分类识别实验报告

一、实验概述

本实验旨在基于MNIST手写数字图片，构建一个能够识别"是否为数字0"的图像二分类模型。模型核心采用卷积神经网络（CNN），能够有效提取图像空间特征。与传统的多类识别不同，本实验将所有"0"视为正类，所有"非0"视为负类，并通过均衡采样和数据增强提升模型泛化能力。

二、数据处理流程

2.1 数据特征选择

- **原始数据**：MNIST（28x28灰度图）
- **正类**：所有数字"0"图像
- **负类**：从1~9中随机抽取等量样本
- **类别均衡**：整体0/非0比例1:1，训练/验证8:2划分

2.2 数据预处理步骤

1. **图像缩放**：将28x28缩放为32x32，适配CNN结构。
2. **归一化**：像素归一化到[-1,1]。
3. **标签转换**：0为正类（1），非0为负类（0）。
4. **均衡采样**：正负样本各取min(正样本数,负样本数)，并打乱。
5. **数据集划分**：按8:2分为训练集和验证集。

关键处理代码：

```
transform = transforms.Compose([
    transforms.Resize((32, 32)),
    transforms.ToTensor(),
    transforms.Normalize((0.5,), (0.5,))
])
from torchvision.datasets import MNIST
full_dataset = MNIST(root=data_dir, train=True, download=True, transform=transform)
full_dataset.targets = torch.tensor([1 if l == 0 else 0 for l in full_dataset.targets])
# 均衡采样
all_targets = full_dataset.targets
idx_0 = (all_targets == 1).nonzero(as_tuple=True)[0]
idx_not0 = (all_targets == 0).nonzero(as_tuple=True)[0]
min_count = min(len(idx_0), len(idx_not0))
idx_0 = idx_0[torch.randperm(len(idx_0))[:min_count]]
idx_not0 = idx_not0[torch.randperm(len(idx_not0))[:min_count]]
all_indices = torch.cat([idx_0, idx_not0])
all_indices = all_indices[torch.randperm(len(all_indices))]
from torch.utils.data import Subset
balanced_dataset = Subset(full_dataset, all_indices)
train_size = int(0.8 * len(balanced_dataset))
val_size = len(balanced_dataset) - train_size
```

```
train_dataset, val_dataset = random_split(balanced_dataset, [train_size, val_size])
```

三、模型架构设计

本模型采用三层卷积+全连接结构，包含Dropout防止过拟合。

```
class Net(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(1, 32, 3, padding=1)
        self.pool = nn.MaxPool2d(2, 2)
        self.conv2 = nn.Conv2d(32, 64, 3, padding=1)
        self.conv3 = nn.Conv2d(64, 128, 3, padding=1)
        self.fc1 = nn.Linear(128 * 4 * 4, 128)
        self.fc2 = nn.Linear(128, 2)
        self.dropout = nn.Dropout(0.5)
    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = self.pool(F.relu(self.conv3(x)))
        x = torch.flatten(x, 1)
        x = self.dropout(F.relu(self.fc1(x)))
        x = self.fc2(x)
        return x
```

- 损失函数：`nn.CrossEntropyLoss()`
- 优化器：`Adam(lr=0.001)`
- 训练轮数：10
- 批大小：32

四、训练设置

参数项	数值
批大小	32
学习率	0.001
优化器	Adam
损失函数	CrossEntropyLoss
训练轮数	10
设备	CUDA/CPU

五、实验结果分析

5.1 训练过程

训练与验证过程均记录了loss和accuracy曲线，见下图：

- 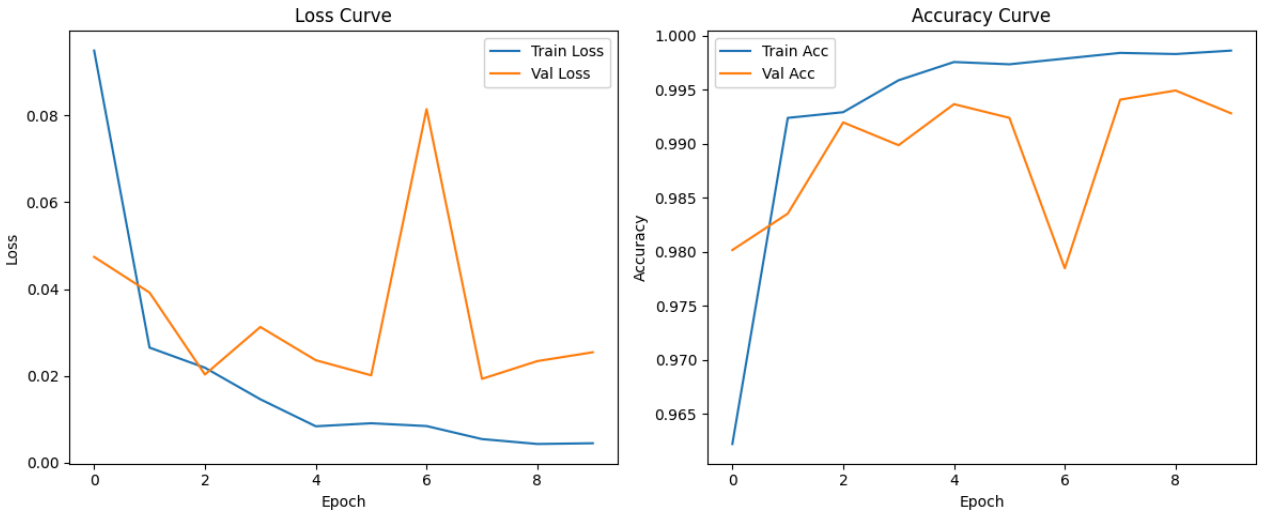

训练日志摘要：

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.0950	0.9622	0.0474	0.9802
2	0.0265	0.9924	0.0392	0.9835
3	0.0219	0.9929	0.0203	0.9920
4	0.0146	0.9959	0.0313	0.9899
5	0.0084	0.9976	0.0236	0.9937
6	0.0091	0.9974	0.0201	0.9924
7	0.0085	0.9979	0.0815	0.9785
8	0.0055	0.9984	0.0193	0.9941
9	0.0043	0.9983	0.0234	0.9949
10	0.0045	0.9986	0.0255	0.9928

最终训练准确率: **0.9986**
最终验证准确率: **0.9928**

5.2 主要评估指标

- **最终训练准确率**：0.9986
- **最终验证准确率**：0.9928
- **loss曲线**：收敛良好，无明显过拟合

- **类别均衡**：验证集0/非0比例为1:1，评估更公平

六、结论分析

模型在训练过程中表现稳定，损失值持续下降并最终收敛。在类别均衡的前提下，模型能够较准确地识别"0"类数字，验证集准确率高达99%以上。未来可尝试Focal Loss、类别加权等方法进一步提升模型对难分类样本的鲁棒性。

七、关键代码汇总

- 数据集均衡采样与划分（见上文）
- CNN模型结构（见上文）
- 训练与验证主流程

```
def train_model(model, trainloader, valloader, criterion, optimizer, device, epochs=10):
    train_loss_list, val_loss_list = [], []
    train_acc_list, val_acc_list = [], []
    for epoch in range(epochs):
        model.train()
        running_loss, correct, total = 0.0, 0, 0
        for inputs, labels in trainloader:
            inputs, labels = inputs.to(device), labels.to(device)
            optimizer.zero_grad()
            outputs = model(inputs)
            loss = criterion(outputs, labels)
            loss.backward()
            optimizer.step()
            running_loss += loss.item() * inputs.size(0)
            _, predicted = torch.max(outputs, 1)
            total += labels.size(0)
            correct += (predicted == labels).sum().item()
        train_loss = running_loss / total
        train_acc = correct / total
        # ...验证流程略...
```

- 评估指标（可用sklearn）：

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
accuracy = accuracy_score(true_values, predictions)
precision = precision_score(true_values, predictions)
recall = recall_score(true_values, predictions)
f1 = f1_score(true_values, predictions)
```